

Primjena mašinskog učenja u predikciji dijabetesa

1. Definicija problema

Dijabetes je hronično oboljenje koje često ostaje neprepoznato u ranoj fazi, što može dovesti do ozbiljnih zdravstvenih komplikacija. Trenutno, rani skrining zahtijeva medicinske preglede i laboratorijske testove, što može biti skupo ili nepristupačno za neke korisnike. Problem koji ovaj projekat rješava je **predviđanje prisustva dijabetesa kod osobe koristeći dostupne zdravstvene i demografske podatke**, bez potrebe za neposrednim medicinskim testovima. Projekat omogućava razvoj sistema koji može pomoći u ranom otkrivanju dijabetesa, podršci ljekarima i samoprocjeni korisnika. Cilj projekta je napraviti sistem koji predviđa da li osoba ima dijabetes na osnovu zdravstvenih i demografskih podataka.

2. Motivacija

Rano otkrivanje dijabetesa je ključno, a mašinsko učenje može pomoći u identifikaciji rizičnih slučajeva. Povećava svijest o važnosti prevencije i može biti temelj za buduće zdravstvene aplikacije.

3. Skup podataka

Baza podataka je preuzeta sa [HuggingFace](#), [CDC Health Indicators](#).

- [CDC Health Indicators](#) - 243,532 instanci
 - **Ciljno obelježje:** *Diabetes_binary* - da li osoba ima dijabetes ("Diabetic": 13.9%, "Non-diabetic": 86.1%)
 - *BMI* (numeric) - indeks tjelesne mase.
 - *Age* (ordinal): starosna grupa (npr 18-24, 25-29...)
 - *GenHlth* (ordinal) - samoprocjena generalnog zdravstvenog stanja (Fair, Good, Poor, Very Good, Excellent).
 - *MenthHlth* (numeric) - broj dana u zadnjih 30 u kojima je mentalno zdravlje bilo loše.
 - *PhysActivity* (ordinal) - ocjena nivoa fizičke aktivnosti.
 - *Income* (ordinal) - kategorija prihoda.
 - *HighBP* (nominal) - da li osoba ima povišen krvni pritisak (da/ne).
 - *HighChol* (nominal) - da li osoba ima povišen holesterol (da/ne).
 - *Smoker* (nominal) - da li je osoba pušač.
 - *Stroke* (nominal) - da li je osoba ikada imala moždani udar.
 - *Sex* (nominal) - Pol
 - *Fruits* (nominal) - da li osoba konzumira voće.
 - *Veggies* (nominal) - da li osoba konzumira povrće.
 - *AnyHealthcare* (nominal) - da li osoba ima bilo kakav oblik zdravstvenog osiguranja.
 - *Education* (ordinal) - najviši stepen obrazovanja.
 - *HeartDiseaseorAttack* (nominal) - da li imaju istoriju sa srčanim bolestima ili udarima.
 - *NoDocbcCost* (nominal) - da li osoba nije mogla da posjeti ljekara zbog troškova.

4. Eksplorativna analiza podataka (EDA) - proširena verzija

Prije treniranja modela, izvršena je detaljna eksplorativna analiza podataka (EDA) kako bi se razumjele karakteristike skupova podataka i identifikovali eventualni problemi koji mogu uticati na performanse modela. EDA je sastavljena od sljedećih koraka:

1. **Pregled distribucije ciljnih i ulaznih atributa**
 - Analizirana je raspodjela ciljnih varijabli (`Diabetes_binary`) kako bi se provjerila neuravnoteženost klasa.
 - Za numeričke attribute (npr. BMI, PhysHlth, MentHlth) prikazane su osnovne statistike: minimum, maksimum, srednja vrijednost, medijana, standardna devijacija.
 - Za kategorijske attribute (npr. Sex, Smoker, HighBP) prikazani su brojači po kategorijama, što pomaže u identifikaciji rijetkih vrijednosti ili potencijalno problematičnih klasa.
2. **Vizualizacija podataka**
 - Histogrami i box-plotovi korišteni su za pregled raspodjele numeričkih atributa i identifikaciju outlier-a.
 - Bar grafovi i pie chart-ovi korišteni su za kategorizovane attribute kako bi se vizualno sagledala zastupljenost svake kategorije.
 - Heatmap korelacija između numeričkih atributa i ciljne varijable omogućava identifikaciju snažnih linearnih ili nelinearnih veza.
3. **Identifikacija outlier-a i nepravilnih vrijednosti**
 - Nepravilne ili ekstremne vrijednosti analizirane su klasičnom metodom IQR kako bi se odlučilo da li ih ukloniti ili transformisati.
 - **MLP Autoencoder** korišten je za identifikaciju redova koji se razlikuju od glavnog obrasca podataka — tj. potencijalnih outlier-a, na osnovu visoke rekonstrukcione greške.
 - Za kategorijske attribute identifikovane su rijetke ili neuobičajene kategorije koje mogu zahtijevati spajanje ili kodiranje.
4. **Imputacija nedostajućih vrijednosti**
 - Nedostajući numerički atributi imputirani su pomoću **MLPRegressor** modela, koji predviđa nedostale vrijednosti na osnovu drugih numeričkih atributa.
 - Ovim se smanjuje potencijalna pristrasnost ili gubitak podataka usljed uklanjanja redova sa nedostajućim vrijednostima.
5. **Analiza korelacija**
 - Korelacija Pearson i Spearman korištena je za numeričke attribute kako bi se uočili potencijalni linearni i monotoni odnosi sa ciljnim atributom.
 - Kontingencijska analiza i chi-square test korišteni su za kategorijske attribute kako bi se procijenila njihova povezanost sa dijabetesom.
 - Rezultati korelacija korišteni su za odabir relevantnih karakteristika i smanjenje redundantnih atributa.
6. **Vizualizacija i analiza istraživačkih pitanja**

Posebna pažnja posvećena je interesantnim pitanjima koja mogu imati kliničko značenje:

 - Starosna grupa i BMI: scatter plot i box-plot prikazuju kako starost i BMI utiču na rizik od dijabetesa.
 - Pušenje, hipertenzija i srčane bolesti: grupisani bar grafovi i stacked bar grafovi pokazuju distribuciju dijabetesa u zavisnosti od prisustva ovih faktora.

- Raspodjela numeričkih vrijednosti kod dijabetičara i nedijabetičara: box-plotovi, violin plotovi i MLP rekonstrukciona greška pokazuju razlike i identifikaciju outlier-a.
- Višedimenzionalni uvid: pairplot-ovi (scatter matrix) korišteni su za vizualizaciju međusobnih odnosa više atributa istovremeno.

7. Zaključci iz EDA

- EDA je omogućila identifikaciju ključnih atributa koji imaju najveći uticaj na diabetes.
- Outlier-i i nepravilnosti u podacima su evidentirani i pripremljeni za čišćenje i standardizaciju, uključujući MLP autoencoder identifikovane outlier-e.
- Rezultati EDA poslužili su za informisano odabiranje modela, hiperparametara i interpretaciju performansi modela nakon treniranja.

4. Način pretprocesiranja podataka

4.1 Konverzija ordinalnih atributa:

- U *CDC Health Indicators* datasetu atributi poput *Age*, *GenHlth* i *Education* pretvoreni su u numeričke vrijednosti prema unaprijed definisanim mapiranjima.

4.2 Rukovanje nedostajućim vrijednostima

- Za numeričke podatke korišten je *SimpleImputer** sa strategijom popunjavanja srednjom vrijednošću (*mean*).
- Za kategorijske podatke korišten je *SimpleImputer** sa strategijom popunjavanja najčešćom vrijednošću (*most frequent*).

Nakon testiranja, strategije sa najboljim performansama su upisane u fajl sa konstantama, te se lako mogu naknadno promijeniti.

4.3 Standardizacija numeričkih vrijednosti

- Numerički atributi (*BMI*, *MentHlth*, itd.) standardizovani su pomoću *StandardScaler** kako bi se uklonile razlike u mjerilima.

4.4 Kodiranje nominalnih vrijednosti

- Nominalni atributi (npr. *Smoker*, *HighBP*, *Gender*, *Smoking_history*) kodirani su pomoću *OneHotEncoder** sa opcijom *drop="if_binary"* radi optimizacije broja kolona.

4.5 Podjela na karakteristike i ciljnu varijablu

- Iz skupa podataka je uklonjena ciljna kolona (*Diabetes_binary* ili *diabetes*) za formiranje ulazne matrice X.

*SimpleImputer, StandardScaler i OneHotEncoder pripadaju biblioteci [scikit learn](https://scikit-learn.org/).

5. Metodologija

Projekat koristi četiri modela mašinskog učenja:

1. **Random Forest**
2. **K-Nearest Neighbors (KNN)**
3. **Gradient Boosting**
4. **Neuronska mreža – Multilayer Perceptron (MLP)**
 - MLP je odabran zbog sposobnosti učenja nelinearnih odnosa između karakteristika i ciljne varijable.

Hiperparametri:

- Optimizovani korištenjem GridSearchCV sa metrikom tačnosti.
- Nakon testiranja, najbolji parametri su fiksirani za finalno treniranje modela.

Fleksibilnost:

- Projekat je dizajniran tako da dodavanje novih modela zahtijeva minimalne promjene.

6. Način evaulacije

Podaci su podeljeni na 80% train i 20% test (stratifikovano).

Evaluacija se vrši pomoću tačnosti i metrika iz *classification report*-a (*precision*, *recall*, *F1-score*). Prikazuju se i bar graf predikcija te log-loss i train/val loss grafikoni.

7. Tehnologije

Biblioteke: scikit-learn, numpy, matplotlib, huggingface_hub, pandas

8. Relevantna literatura

<https://www.analyticsvidhya.com/blog/2022/01/diabetes-prediction-using-machine-learning/>

<https://ai.plainenglish.io/diabetes-prediction-using-machine-learning-classification-approaches-a-capstone-project-by-team-cbd0b784a30b>